



VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ

BRNO UNIVERSITY OF TECHNOLOGY

FAKULTA INFORMAČNÍCH TECHNOLOGIÍ

FACULTY OF INFORMATION TECHNOLOGY

ÚSTAV INFORMAČNÍCH SYSTÉMŮ

DEPARTMENT OF INFORMATION SYSTEMS

**DISTRIBUOVANÝ REPOSITÁŘ DIGITÁLNÍCH FORENZ-
NÍCH DAT**

DISTRIBUTED FORENSIC DIGITAL DATA REPOSITORY

SEMESTRÁLNÍ PROJEKT

TERM PROJECT

AUTOR PRÁCE

AUTHOR

Bc. MARTIN JOSEFÍK

VEDOUcí PRÁCE

SUPERVISOR

RNDr. MAREK RYCHLÝ, Ph.D.

BRNO 2018

Zadání diplomové práce

Řešitel: **Josefík Martin, Bc.**

Obor: Informační systémy

Téma: **Distribuovaný repositář digitálních forenzních dat**
Distributed Forensic Digital Data Repository

Kategorie: Databáze

Pokyny:

1. Seznamte se s formáty digitálních forenzních dat a způsoby jejich uložení. Prozkoumejte existující systémy pro uložení digitálních forenzních dat (např. AFF4). Seznamte se s distribuovanými databázemi a úložišti pro rozsáhlá strukturovaná i nestrukturovaná data.
2. Navrhněte distribuované úložiště rozsáhlých digitálních forenzních dat (Big data) vč. aplikačního rozhraní pro optimální přístup k různým datům (sekvenční a náhodní čtení, dotazování, zpracování Big data přístupy). Zvolte vhodné technologie pro implementaci úložiště.
3. Po konzultaci s vedoucím navržené úložiště implementujte. Úložiště musí umožňovat přidávání podpory pro nové druhy forenzních dat za běhu. Otestujte použití a výkon úložiště pro vybrané druhy digitálních forenzních dat.
4. Výsledky zdokumentujte, vyhodnoťte a projekt zveřejněte jako open-source.

Literatura:

- Advanced Forensic Framework 4 (AFF4). [<http://forensicswiki.org/wiki/AFF4>]
- Quick, Darren, Kim-Kwang Raymond Choo. "Big forensic data reduction: digital forensic images and electronic evidence". *Cluster Computing* 19.2 (2016): 723-740.

Při obhajobě semestrální části projektu je požadováno:

- Body 1 a 2.

Podrobné závazné pokyny pro vypracování diplomové práce naleznete na adrese

<http://www.fit.vutbr.cz/info/szz/>

Technická zpráva diplomové práce musí obsahovat formulaci cíle, charakteristiku současného stavu, teoretická a odborná východiska řešených problémů a specifikaci etap, které byly vyřešeny v rámci dřívějších projektů (30 až 40% celkového rozsahu technické zprávy).

Student odevzdá v jednom výtisku technickou zprávu a v elektronické podobě zdrojový text technické zprávy, úplnou programovou dokumentaci a zdrojové texty programů. Informace v elektronické podobě budou uloženy na standardním nepřepisovatelném paměťovém médiu (CD-R, DVD-R, apod.), které bude vloženo do písemné zprávy tak, aby nemohlo dojít k jeho ztrátě při běžné manipulaci.

Vedoucí: **Rychlý Marek, RNDr., Ph.D.,** UIFS FIT VUT

Datum zadání: 1. listopadu 2017

Datum odevzdání: 23. května 2018

VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ
Fakulta Informačních technologií
Ústav informačních systémů
602 00 Brno, Božetěchova 2

doc. Dr. Ing. Dušan Kolář
vedoucí ústavu

Abstrakt

Tato práce se zabývá návrhem distribuovaného repositáře zaměřeného jako úložiště rozsáhlých digitálních forenzních dat. Teoretická část práce pojednává o forenzní analýze digitálních dat a co je jejím cílem. Současně také vysvětluje Big data, vhodné úložiště, jejich vlastnosti, výhody a nevýhody. Hlavní část práce se pak zabývá návrhem a implementací distribuovaného úložiště pro digitální forenzní data. Návrh se rovněž zaměřuje na vhodnou indexaci uložených dat a rozšiřitelnost pro podporu nových druhů digitálních forenzních dat do budoucna.

Abstract

This work deals with the design of distributed repository aimed at storing digital forensic data. The theoretical part of the thesis describes digital forensics and what is its purpose. There are also explained Big data, suitable storages, their properties, advantages and disadvantages, in this part. The main part of the thesis deals with the design and implementation of distributed storage for digital forensic data. The design is also focused in suitable indexing of stored data, and supporting new types of digital forensic data.

Klíčová slova

Big data, forenzní analýza digitálních dat, formáty digitálních forenzních dat, AFF4, distribuované databáze, NoSQL databáze, Kafka, Big data přístupy a technologie, asynchronní komunikace

Keywords

Big data, digital forensics, forensics file formats, AFF4, distributed databases, NoSQL databases, Kafka, Big data approaches and technologies, asynchronous communication

Citace

JOSEFÍK, Martin. *Distribuovaný repositář digitálních forenzních dat*. Brno, 2018. Semestrální projekt. Vysoké učení technické v Brně, Fakulta informačních technologií. Vedoucí práce RNDr. Marek Rychlý, Ph.D.

Distribuovaný repositář digitálních forenzních dat

Prohlášení

Prohlašuji, že jsem tento semestrální projekt vypracoval samostatně pod vedením pana RNDr. Marka Rychlého, Ph.D. Uvedl jsem všechny literární prameny a publikace, ze kterých jsem čerpal.

.....

Martin Josefík

1. dubna 2018

Poděkování

Rád bych touto cestou poděkoval vedoucímu mého semestrálního projektu panu RNDr. Markovi Rychlému, Ph.D. za odborné vedení, poskytované rady a připomínky v průběhu řešení práce.

Obsah

1	Úvod	3
2	Forenzní analýza digitálních dat	4
2.1	Formáty digitálních forenzních dat	5
2.2	Existující systémy	6
2.2.1	AFF4	6
3	Úložiště pro rozsáhlá strukturovaná i nestrukturovaná data	8
3.1	Big data	8
3.2	Distribuované databáze	9
3.2.1	Rozdělení	11
3.3	Úložiště	12
3.3.1	Strukturovaná data	12
3.3.2	Nestrukturovaná data	12
4	Návrh distribuovaného úložiště	13
4.1	Aplikační rozhraní	13
4.1.1	Komunikace	13
4.2	Úložiště	16
4.2.1	Strukturovaná data	16
4.2.2	Nestrukturovaná data	16
4.2.3	Metadata	16
4.3	Zpracování zpráv	17
4.4	Architektura	18
5	Implementace prototypu	20
5.1	Výkon	20
6	Implementace	22
6.1	Rozhraní pro dotazování dat	22
6.2	Moduly, knihovny a frameworky	22
6.2.1	Pcap4J	23
6.3	Scénáře	24
6.3.1	Ukládání paketů	24
6.3.2	Čtení paketů	24
6.4	Komunikace s databázemi	24
6.4.1	Reaktivní paradigma	24
6.4.2	Asynchronní dotazy	24

6.5	Logování	24
6.6	Zpracování chyb	24
7	Výkon	25
8	Závěr	26
	Literatura	27

Kapitola 1

Úvod

Během začátku 21. století došlo k ohromnému růstu v oblastech internetu, sociálních sítí, multimédií, chytrých telefonů a dalších zařízení, či mobilních plateb a on-line transakcí. V podstatě ve všech oblastech jako je například věda, politika, strojírenství, medicína, doprava, energetika, se nevyhneme použití digitálních zařízení. S tím velmi úzce souvisí nárůst objemu digitálních dat, která je potřeba ukládat, analyzovat, zpracovávat, a také vyšetřovat.

Digitální zařízení se mohou stát terčem útoků, může se jednat o krádež citlivých dat, podvržení dat, sledování a další. Digitální zařízení mohou být také nástrojem zločinu.

Rozdílnost mezi formáty digitálních dat, jejich strukturované a nestrukturované vlastnosti, a také prudký nárůst vyžadují mnoho rozličných přístupů a technologií pro jejich zpracování.

Cílem této práce je navrhnout a vytvořit distribuované úložiště pro digitální forenzní data. V rámci teoretické části práce, se kapitola 2 zaměřuje na forenzní analýzu digitálních dat, vysvětluje, jak probíhá a co je jejím cílem. Zabývá se také formáty digitálních forenzních dat a existujícími systémy, které slouží k uchování těchto dat a důkazního materiálu. Následně je představen systém AFF4.

Kapitola 3 pojednává o úložištích pro rozsáhlá strukturovaná i nestrukturovaná data. V jejich kontextu vysvětluje také termín Big data. Následující odstavce zaměřeny na distribuované databáze včetně jejich výhod a nevýhod. Kapitola je završena uvedením principů NoSQL databází, rozdělení podle typů, a srovnání s relačními databázemi. Na NoSQL databázích bude založeno úložiště distribuovaného repositáře.

Cílem praktické části práce je navrhnout a implementovat distribuovaný repositář. V kapitole návrhu 4 je vysvětlena architektura systému, aplikační rozhraní, vlastnosti úložiště, princip ovládání repositáře a také rozšiřitelnost pro nové druhy digitálních forenzních dat. Systém využívá Big data technologie. Pro komunikaci s klientem jsou zprávy přenášeny tzv. **Message brokerem** Kafka. Jako úložiště slouží, v závislosti na tom, o jaký typ forenzních digitálních dat se jedná, NoSQL databáze a distribuovaný souborový systém HDFS.

Kapitola 6 se zabývá implementací distribuovaného úložiště, technickými detaily, způsobem asynchronní komunikace s databázemi, ukládáním a dotazováním nad daty (sekvenčním i náhodným). Systém pracuje nad frameworkem Spring, který usnadňuje konfiguraci a použití Big data komponent. Jako běhové prostředí byl zvolen projekt **Docker**, který poskytuje jednotné rozhraní pro izolaci aplikací do kontejnerů.

Poslední kapitola 7 se věnuje výkonnosti systému, hardwarovým požadavkům a konfiguraci, a použití systému pro vybrané druhy digitálních forenzních dat.

Kapitola 2

Forenzní analýza digitálních dat

Forenzní analýza digitálních dat je věda identifikující, zachovávající, obnovující, analyzující a předávající fakta ohledně digitálních důkazů nalezených v počítačích nebo digitálních úložištích mediálních zařízení. Nezabývá se tedy pouze počítači, ale také ostatními digitálními technologiemi včetně mobilních telefonů a tabletů, mobilních sítí, internetového bankovníctví, datových médií apod.


Forenzní analýza digitálních dat slouží k získání digitálního důkazního materiálu, který může být použit v soudní síni proti obviněnému. Nalezené výstupy nejsou omezeny k použití pouze u soudu. Častokrát může nějaká firma řešit interní záležitosti jako například porušení firemní politiky, kdy se zase musí najít (digitální) důkaz, který potvrzuje nebo vyvrací obvinění.

Pod výše uvedenými aktivitami se skrývá [14]:

- Identifikace - Jedná se o první část celého procesu. Předtím, než je cokoli zkoumáno a analyzováno, je důležité identifikovat, kde jsou data uložena. Typicky jsou uložena na diskových jednotkách, serverech, flash klíčenkách, síťových zařízeních.
- Zachování - Důležitá je ochrana důkazů, tzn. pro sběr a analýzu informací je potřeba zachovat původní data, musí se zabránit jejich změně a ztrátě. Bez integrity je důkazní materiál nepoužitelný. Identifikovaná původní data mohou být zajištěna chronologickým řetězcem dokumentů (anglicky **chain of custody**), který zaznamenává veškeré aktivity s digitálním důkazem jako je přenos, úschova, kontrola a stav.
- Obnovení - Součástí procesu je i obnova dat, která může zahrnovat obnovu smazaných dat procesy operačního systému, úmyslně smazané soubory, soubory chráněné heslem a také poškozené soubory. I po obnovení smazaného souboru musí být stále zachována integrita.
- Analýza - Jedná se o hlavní část vyšetřování. Cílem je shromáždit co nejvíce relevantních artefaktů. Prohledávána je paměť, registry, výpisy z logů aplikací, historie internetového prohlížeče apod. Podstatná je i dokumentace všech kroků, které byly provedeny.
- Předání - Po analýze jsou artefakty důkladně zdokumentovány a odevzdány například ve formě protokolu. Po shromáždění všech nalezených informací může ale nemusí dojít k definitivnímu rozhodnutí. Co se s informacemi stane už není v rukou vyšetřovatele. Tady proces forenzní analýzy končí.

Vyšetřování digitálních forenzních dat obvykle zahrnuje vytvoření forenzní duplikace zkoumaného média. Provádí se proto, aby se neznehodnotil původní zdroj. Například dojde k vytvoření obrazu disku, který je kopie celého disku nebo jeho části bit po bitu. Neduplikuje se celý systém, pokud je prostor příliš velký. Obraz je statický snímek, který může být analyzován za účelem odhalení nebo stanovení událostí ohledně incidentů, a může tak být použitý jako důkaz v soudní síni. Analýza je prováděna na kopii pro zachování integrity originálu.

Vyšetřovatel zanalyzuje obraz pomocí snímacích technik, aby získal relevantní data z disku. Forenzní obraz obsahuje soubory z disku, ale také nealokovaný prostor a tzv. **slack space**. Slack space je pozůstatek diskového prostoru, který byl alokovan pro nějaký počítačový soubor a ten všechny prostor nepotřebuje. Právě v těchto prostorech mohou být nalezeny relevantní artefakty a informace jako například smazané soubory, či jejich fragmenty [19].



Obrázek 2.1: Příklad znázorňuje slack space pro parametry: sektory velikosti 512 bajtů v operačním systému jsou shluknuty do skupin po čtyřech, tzn. velikost svazku je 2048 bajtů; velikost souboru je 1280 bajtů (modrá barva). Pro tento soubor byl alokován celý svazek 2048 bajtů, nevyužitý místo je slack space, v tomto případě se jedná o 768 bajtů [12].

2.1 Formáty digitálních forenzních dat

Typů digitálních forenzních dat existuje spousta. Každý typ takových dat může být reprezentován jiným formátem. Tato sekce čerpá informace převážně z [6].

Mnoho forenzních počítačových programů používají své vlastní formáty pro uložení informace. Můžeme je rozdělit na nezávislé (anglicky **Independent File Formats**) a programově specifické formáty (anglicky **Program-Specific File Formats**):

- Nezávislé - Tyto formáty byly vyvinuty nezávisle na konkrétním forenzním programu. Patří mezi ně **AFF**, **AFF4**, **gzif**, **Raw Image Format**.

- Programově specifické - Byly vyvinuty pro použití specifickými forenzními programy. Většinou každý takový formát je unikátní, a proto je pro přečtení potřeba unikátního nástroje. Zástupci jsou například Encase image file format, ProDiscover image file format, IXimager file formats.

Identifikace formátu

Identifikace formátu souboru je proces určení formátu nějaké sekvence bajtů. Operační systém toto typicky dělá rozpoznáním přípony souboru nebo podle zabudované MIME informace. Forenzní aplikace musí identifikovat typy souborů podle obsahu. Mezi existující systémy patří například tyto projekty - libmagic, PRONOM, Apache Tika¹ [5].

2.2 Existující systémy

Vyznamným zástupcem pro uložení digitálních forenzních dat je systém AFF4, který bude popsán detailněji.

2.2.1 AFF4

Jedná se o open source formát pro ukládání digitálních důkazů a dat. Jeho výhodami jsou správa metadat a možnost komprese. Tato sekce čerpá převážně z [1]. Je založen na objektově orientované architektuře. Veškerá množina známých objektů je označována jako AFF4 universe. Takový prostor je definovaný jako nekonečný, protože AFF4 je navržen pro škálování obrovského množství důkazního materiálu. Všechny objekty jsou adresovatelné jejich jménem, které je v rámci AFF4 universe unikátní.

Příkladem jména nějakého AFF4 objektu může být:

`urn:aff4:f3eba626-505a-4730-8216-1987853bc4d2`

Jedná se o standardní URN notaci, URN je unikátní.

AFF4 universe používá RDF notaci pro specifikaci atributů objektů. V nejjednodušší podobě je RDF množina tvrzení o objektu ve formátu:

`Subject Attribute Value`

Příklad:

```
***** Object urn:aff4:f3eba626-505a-4730-8216-1987853bc4d2 *****
aff4:stored = urn:aff4:4bdbf8bc-d8a5-40cb-9af0-fd7e4d0e2c9e
aff4:type = image
aff4:interface = stream
aff4:timestamp = 0x49E9DEC3
aff4:chunk_size = 32k
aff4:compression = 8
aff4:chunks_in_segment = 2048
aff4:size = 10485760
```

Příklad ukazuje, že objekt má tyto atributy a hodnoty. Nazýváme je relace nebo fakta. Celý AFF4 universe je sestavený z takových faktů.

¹<http://tika.apache.org/>

AFF4 objekty existují, protože dělají něco užitečného, což závisí na rozhraní, které představují. Aktuálně existuje několik rozhraní, nejvýznamnější jsou **Volume** a **Stream**. Rozhraní objektu je fakt o objektu, který nalezneme v atributu `aff4:interface`.

Rozhraní Volume

Rozhraní Volume definujeme jako mechanismus ukládání, který dokáže uložit segment (bit binárních dat) pod nějaké jméno, a získat jej podle tohoto jména. Aktuálně existují dvě implementace: **Directory** a **ZipFile**.

- **Directory Volume** - Tato implementace ukládá segmenty jako soubory uvnitř běžného adresáře v souborovém systému. Hodí se zejména, pokud potřebujeme uložit obraz na souborový systém FAT, přičemž velikost segmentu je malá a nenarazíme tak na omezení velikosti souboru. Je také možné založit adresář na nějaké http adrese, což nám umožní používat obraz přímo z webu.
- **ZipFile Volume** - Jak napovídá název, tato implementace ukládá segmenty uvnitř zip archivu. Malé soubory lze bez problémů otevřít obyčejným průzkumníkem (windows explorer) a data extrahovat. Zase je možné zapsat zip archiv přímo na HTTP server a používat obraz přímo ze serveru.

Je možné převádět mezi oběma formáty z jednoho na druhý, extrahovat zip archiv do adresáře a vytvoření Directory volume.

Rozhraní Stream

Streamy jsou základním rozhraním pro ukládání dat obrazu. Stream obsahuje metody typu `read`, `seek`, `tell` a `close`. Podporuje ještě `write`, ale ne k modifikaci obrazu, nýbrž k jeho vytvoření (kvůli výše uvedené integritě zdroje). Pokud nějaký AFF4 objekt podporuje rozhraní stream, lze provést náhodné čtení jeho dat. Existuje několik specifických implementací rozhraní stream, některými z nich jsou:

- **FileBackedObjects** - Stream, který ukládá data v souboru v souborovém systému, jehož pozice je určena URN souboru.
- **HTTPObject** - Pozice souboru je udána pomocí URL. Objekt lze ukládat a číst z HTTP serveru. Implementace umožňuje přečíst určité rozmezí bajtů. Režie síťového provozu mezi klientem a serverem je minimální. Je možné vyšetřit vzdálený obraz přes HTTP bez potřeby celé kopie obrazu. Z důvodu bezpečnosti by měl být server pro zápis nějak omezen, například hesly, SSL certifikáty apod. Podpora čtení může být poskytnuta bez omezení, pokud je zdroj dat zašifrován. Zabezpečení serveru je ale mimo rozsah AFF4.
- **Segments** - Segmenty jsou komponenty uloženy přímo ve **Volume**. Volume je zjednodušeně řečeno objekt uchovávající segmenty. Segmenty by měly být použity pro malé streamy, protože prohledávat v komprimovaných segmentech může být drahá operace. Segmenty jsou užitečné, pokud potřebujeme vytvořit logický obraz nějaké podmnožiny souborového systému (pouze některé soubory) a ne forenzní obraz celkového systému.
- **Image streams** - Tyto streamy jsou opakem segmentů. Pro velké obrazy nemůžeme použít segmenty, protože by nebyly zkomprimovány efektivně. Image stream ukládá obraz v tzv. **chunks**.

Kapitola 3

Úložiště pro rozsáhlá strukturovaná i nestrukturovaná data

V této kapitole bude představen a vysvětlen termín Big data, následován systémy a mechanismy pro uložení, jako například distribuované databáze a NoSQL databáze, včetně jejich vlastností, výhod a nevýhod.

3.1 Big data

Definicí pro frázi Big data existuje několik. Jedná se o termín použitý na soubory dat, které jsou příliš komplexní z hlediska velikosti a různorodosti, a které je nemožné zpracovávat běžně používanými přístupy a softwarovými nástroji v rozumném čase.

Objem takových dat rychle roste. Vyskytují se v mnoha odvětvích, například sběr informací o počasí, sociální sítě, energetické a telekomunikační společnosti, ekonomie a finančnictví, či data z kamer, měření z různých senzorů apod. Z toho plyne, že se jedná o data různorodých typů, mohou být strukturovaná i nestrukturovaná. Proto je potřeba existence různých technologií pro jejich uložení, zpracování, analýzu i zobrazení.

Pojem Big data je často definován jako 4V z anglických slov Volume, Velocity, Variety a Value [9]:

- Volume – Značí množství nebo velikost dat. Je vyžadováno zpracování vysokých objemů dat neznámých hodnot, například síťový provoz, data sesbírána ze senzorů apod.
- Velocity – Vyjadřuje rychlost z hlediska vzniku dat a potřeby jejich analýzy, některá vyžadují zpracování v reálném čase. Nejdůležitější data se zapisují přímo do paměti, a ne na disk, z důvodu co nejrychlejšího zpracování.
- Variety – Znamená různorodost typů. Jedná se především o nestrukturovaná data, například text, audio, video, data o geografické poloze a další. Jsou na ně kladeny velmi podobné požadavky jako na data strukturovaná – sumarizace, monitorování, důvěrnost [9].
- Value – Data mají vlastní hodnotu, která musí být analyzována a zjištěna. Nejedná se o jednoduchý proces, je stále potřeba nových metod a technik zpracování.




Obrázek 3.1: S přibývajícími novými technologiemi se masivně zvyšuje růst dat a přibývají nové typy [10].

3.2 Distribuované databáze

Distribuovaná databáze se skládá z většího počtu samostatných databází, které mohou být geograficky rozmístěny na jiných pozicích. Jednotlivé uzly spolu komunikují přes počítačovou síť. Každý uzel je sám o sobě databázový systém. DSŘBD neboli systém řízení distribuované báze dat (anglicky Distributed Database Database Management System) zajišťuje, že se distribuovaná databáze uživatelům jeví jako jedna jediná databáze. Data jsou fyzicky uložena na různých pozicích. Mohou být spravována rozdílnými SŘBD nezávisle na ostatních pozicích.

Systém řízení distribuované báze dat je centralizovaný systém s těmito vlastnostmi [17]:

- Umí vytvářet, získávat, upravovat a mazat distribuované databáze.
- Zajišťuje důvěrnost a integritu databází.
- Periodicky synchronizuje databázi a poskytuje mechanismy přístupu tak, aby se databáze uživatelům jevila transparentní.
- Zajišťuje, že změna dat v kterémkoliv uzlu se promítne i v ostatních uzlech.
- Je využíván v aplikacích, kde se předpokládá zpracování velkých objemů dat, ke kterým přistupuje současně mnoho uživatelů.
- Je navržen pro heterogenní databázové platformy.



Obrázek 3.2: Schéma distribuované databáze a současný přístup více zařízení k ní [11].

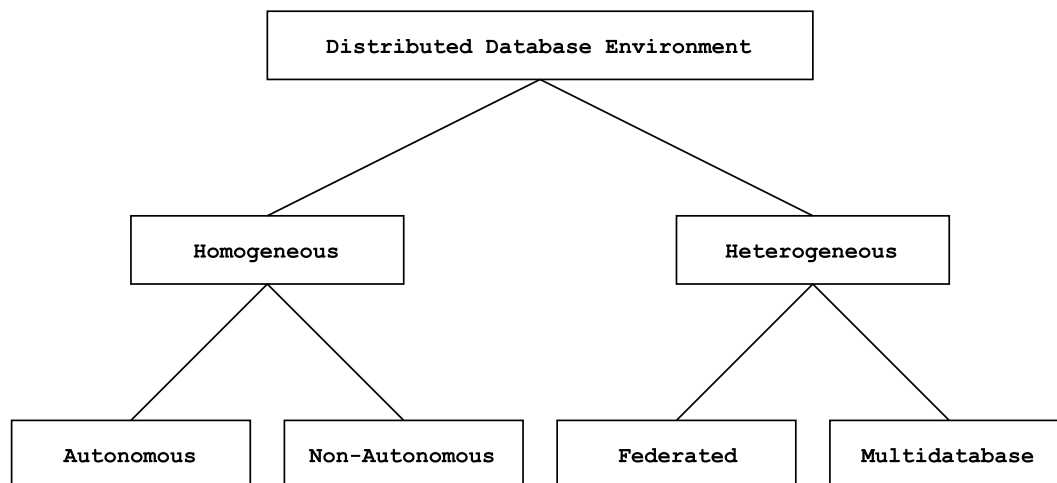
Výhody

- Rozšiřitelnost – Pokud je potřeba databázový systém rozšířit do nových míst nebo přidat další uzly, stačí přidat nový(é) počítač(e) a lokální data v nové pozici, a na konec je připojit k distribuovanému systému, bez jakéhokoliv přerušení funkcionality. Podobný postup je při odebrání uzlu.
- Spolehlivost – Když nějaký z připojených uzlů selže, nepřestane distribuovaná databáze fungovat, sníží se maximálně výkon.
- Ochrana (záloha) dat – Při zničení jednoho uzlu a smazání dat z něj, mohou být stejná data zálohována i na jiných uzlech.
- Výkonnost – Pokud jsou data efektivně distribuována, může být uživatelův požadavek uspokojen rychleji. Transakce mohou být také distribuované a provedeny rychleji.

Nevýhody

- CAP teorem - Pojednává o tzv. eventuální konzistenci (na rozdíl od absolutní konzistence u ACID). Definuje, že distribuovaný systém může zajistit maximálně 2 z těchto 3 vlastností: konzistence (angl. Consistency), dostupnost (angl. Availability) a odolnost k přerušení (angl. Partition tolerance). Je nutné si zvolit mezi konzistencí a dostupností v případě výpadku části sítě.
- Integrita dat – Data musí být průběžně synchronizována na více uzlech, aby na stejné dotazy nebyly z různých uzlů vráceny rozdílné odpovědi.

- Komunikační režie – I zdánlivě jednoduchá operace může vyžadovat spoustu zbytečné komunikace.
- Cena – DSŘDB vyžaduje drahý a složitý software ke koordinaci uzlů a zajištění transparentnosti [17].
- Mezi další patří – složitost, zabezpečení, řízení souběžného přístupu k datům.



Obrázek 3.3: Distribuované databáze můžeme podle jejich vlastností dělit [17].

3.2.1 Rozdělení

Homogenní

Všechny uzly používají identické SŘBD a operační systémy. Uzly mají informace o ostatních uzlech a spolupracují při zpracování uživatelských požadavků. Homogenní distribuovaná databáze se navenek jeví uživateli jako jeden systém. Je jednodušší jej navrhnout a spravovat.

Autonomní - Každá databáze je nezávislá, neexistuje žádný centrální uzel. Databáze jsou spravovány aplikací, a pro předávání dat používají zasílání zpráv.

Neautonomní - Data jsou distribuována napříč homogenními uzly. O aktualizaci a správu dat se stará systém řízení distribuované báze dat, který běží na centrálním nebo také master uzlu.

Heterogenní

Uzly mohou mít rozdílné operační systémy a SŘBD, které nejsou kompatibilní. Mohou také využívat rozdílná schémata (relační, objektově orientované, hierarchické, ...). Rozdílnost schématu je hlavním problémem při zpracování dotazu a transakcí. Kvůli tomu je také složité dotazování [4]. Heterogenní distribuované databáze můžeme rozdělit na federované (angl. federated) nebo multidatabázové.

Architekturami distribuovaných databází jsou centrální architektura, klient-server, peer-to-peer, multi-databázová architektura.

3.3 Úložiště

V této sekci budou popsána strukturovaná a nestrukturovaná data, jaký je mezi nimi rozdíl a jaká jsou jejich úložiště.

3.3.1 Strukturovaná data

Strukturovanými daty jsou libovolná data, pro která lze sestavit datový model. Datový model přesně organizuje jednotlivé elementy dat a specifikuje, jak spolu elementy souvisí, jaké mají vazby, jak budou uloženy, přístup k nim, a jak souvisí s jednotlivými elementy reálného světa [2]. Typickým úložištěm strukturovaných dat je relační databáze. Pro čtení a dotazování byl vytvořen dotazovací jazyk SQL.

3.3.2 Nestrukturovaná data

Jak už bylo zmíněno v sekci 3.1, Big data patří převážně mezi nestrukturovaná data. Data nemají přesně definovanou strukturu, neexistuje datový model, který by definoval jednotlivé dílčí elementy a jejich vztahy. Mezi typické zástupce patří: videa, obrázky, audio, webové stránky, text, obsah e-mailové komunikace apod. Mezi vhodná úložiště mohou patřit disková úložiště, NAS (celým názvem **Network Attached Storage**), HDFS (**Hadoop Distributed File System**) a NoSQL databáze.

NoSQL databáze

Pod zkratkou se nachází **non SQL** nebo také **Not only SQL**. Jedná se o databázový koncept, ve kterém datové úložiště i zpracování dat používají jiné prostředky než tabulková schémata tradiční relační databáze [7]. NoSQL databáze jsou navrženy pro distribuovaná ukládání a dotazování dat, souběžný přístup, a manipulaci s obrovským objemem dat. Mezi výhody patří: horizontální i vertikální škálovatelnost, distribuovaný přístup, flexibilita schématu, dynamičnost. Nevýhodami však mohou být: absence standardizace, omezené schopnosti dotazování, konzistence [8].

NoSQL databáze mohou být rozděleny do čtyř kategorií [13]:

- Klíč-hodnota (angl. Key-Value databases) - Jsou nejjednoduššími NoSQL úložišti. Každá položka v databázi je uložena jako atribut (klíč) společně se svou hodnotou. Hodnota je typu **blob**, takže pouze aplikace dokáže hodnotu správně interpretovat. Zástupci jsou databáze **Riak** a **Redis**.
- Dokumentové (angl. Document databases) - Párují každý klíč se složitou datovou strukturou, nazývanou dokument. Dokument může obsahovat mnoho rozdílných párů klíč-hodnota, párů klíč-pole, nebo dokonce vnořené dokumenty. Jsou vhodné pro dokumenty typu XML a JSON. Mezi zástupce patří **MongoDB** a **CouchDB**.
- Grafové (angl. Graph databases) - Jsou navrženy pro ukládání entit (uzly) a jejich vztahů (hrany). Uzly i hrany mohou mít svoje atributy. Zástupcem je **Neo4J**.
- Sloupcové (angl. Column-oriented databases / Column family stores) - Ukládají data ve sloupcích místo řádků, jsou optimalizovány pro dotazování nad velkými objemy dat. Zástupci jsou například **Cassandra** a **HBase**.

Kapitola 4

Návrh distribuovaného úložiště

Tato kapitola se zabývá návrhem distribuovaného úložiště rozsáhlých digitálních forenzních dat. Bude popsána architektura systému včetně aplikačního rozhraní a použité technologie pro vytvoření distribuovaného repositáře. Systém bude založen na Big data technologiích - Kafka (společně se ZooKeeper), NoSQL databáze, případně Hadoop a Spark. Jak jednotlivé technologie fungují bude vysvětleno v této kapitole.

4.1 Aplikační rozhraní

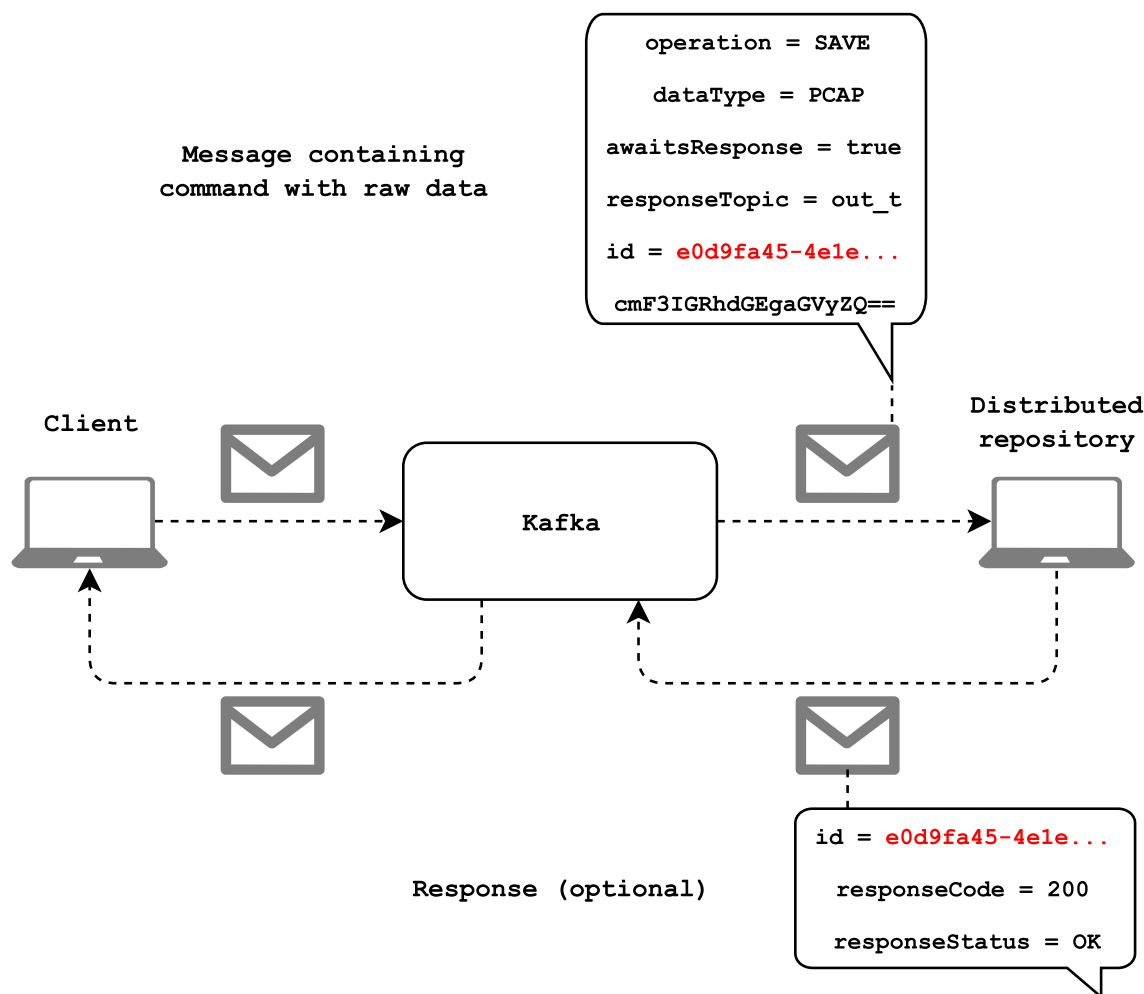
Aplikační rozhraní umožňuje klientovi komunikovat s distribuovaným repositářem. Komunikace je založena na asynchronním zasílání zpráv. Systém repositáře nenabízí klientovi přímo žádné metody či funkce, které by klient mohl volat. Ovládání repositáře probíhá pomocí zaslání zprávy obsahující tzv. příkaz. Podle typu operace a typu dat je určeno, jak se daný příkaz zpracuje. V následující sekci bude vysvětleno, jak ovládání repositáře probíhá, jak vypadá zpráva, a bude také uvedeno schéma celé komunikace jako příklad.

4.1.1 Komunikace

Komunikace s klientem, který chce do distribuovaného repositáře data uložit, nebo naopak z něj nějaká data získat, probíhá pomocí zaslání zprávy tzv. **MQ brokeru** Kafka. Zpráva obsahuje parametry - atributy příkazu a řetězec dat. Atributy příkazu udávají následující informace:

- **operation** - o jakou operaci se jedná, výchozí operace jsou **SAVE**, **LOAD**,
- **dataType** - typ dat, výchozími typy jsou **Text**, **PCAP**, **Packet**,
- **id** - unikátní ID zprávy, aby klient potom dokázal identifikovat už zpracované příkazy,
- **awaitsResponse** - jestli klient/odesílatel zprávy očekává od repositáře odpověď,
- **responseTopic** - ve které frontě (angl. topic) je odpověď na straně klienta očekávána,
- případně další potřebné atributy.

Řetězec dat obsahuje vlastní data, která mají být na straně repositáře zpracována. Typy operací a typy dat lze libovolně přidávat.



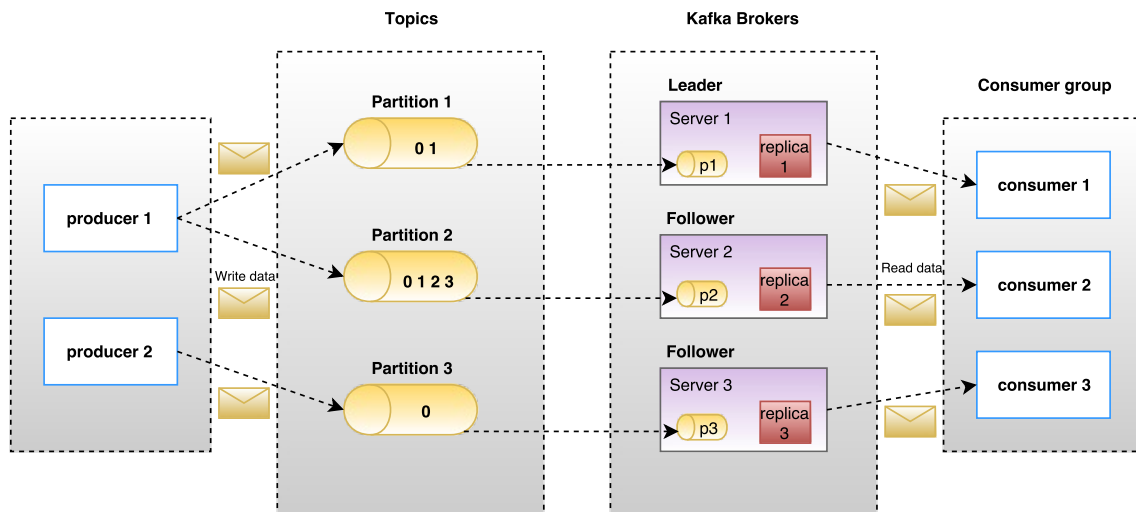
Obrázek 4.1: Příklad komunikace - klient zašle příkaz přes Kafku, příkaz je zpracován na straně distr. repositáře, a případně je odeslána odpověď klientovi. Můžeme si všimnout uvedených ID, jsou stejné - klient zjistí, ke kterému příkazu odpověď patří.

Kafka

Apache Kafka je distribuovaný systém zpráv s robustními frontami založený na mechanismu **publish-subscribe** umožňující přenášet vysoké objemy dat. Kafka zprávy jsou perzistentně uloženy na disku a replikovány v rámci clusteru kvůli prevenci ztráty dat. Framework Kafka je postaven na synchronizační službě ZooKeeper [15].

Výhody jsou:

- Spolehlivost - Kafka je distribuovaný systém, segmentovaný, replikovaný a odolný proti chybám.
- Rozšiřitelnost - Možnost připojení nových uzlů do clusteru.
- Odolnost - Zprávy jsou uloženy na disku.
- Výkon - Vysoká propustnost pro obě akce **publish** a **subscribe**. Je zachován stabilní výkon i při objemu zpráv v terabytech.



Obrázek 4.2: Diagram zobrazující klíčové komponenty systému Kafka [15].

V diagramu 4.2 je fronta (angl. topic) konfigurována do tří oddílů (angl. partition). Pokud je faktor replikace fronty nastaven na hodnotu 3, Kafka vytvoří tři identické repliky každého oddílu a umístí je do clusteru. Každý prostředník (angl. broker) ukládá jeden nebo více těchto oddílů za účelem vyvažování zátěže. Více producentů, respektive konzumentů, může zároveň vydávat (angl. publish), resp. odebírat, (angl. subscribe) zprávy [15].

Hlavní komponenty systému Kafka z diagramu 4.2:

- Fronta - Jedná se o proud zpráv patřící k příslušné kategorii. Data jsou uložena ve frontách. Fronty jsou rozděleny do oddílů.
- Oddíl - Fronty mohou mít mnoho oddílů, tak aby zvládaly zpracování libovolného množství dat.
- Offset oddílu (angl. Partition offset) - Každá zpráva v oddílu má unikátní sekvenci ID nazývanou offset.
- Replika oddílu - Je pouhou zálohou oddílu. Repliky nejsou využívány ke čtení nebo zápisu dat, slouží pouze jako prevence před ztrátou dat.
- Prostředník - Jednoduchý systém zodpovědný za správu dat v oddílech, resp. frontách. Prostředníci slouží k balancování zátěže.
- Kafka Cluster - Pokud existuje víc než jeden prostředník, pak se systém nazývá cluster. Cluster může být rozšířen bez prodlev o další prostředníky.
- Producent - Je odesílatel zprávy do jedné nebo více Kafka front. Producenti posílají data prostředníkům. Pokaždé když producent pošle zprávu prostředníkovi, prostředník přidá zprávu na konec oddílu. Producent nečeká na žádná potvrzení, posílá zprávy tak rychle, jak jen prostředník dokáže přijímat.
- Konzument - Čte data od prostředníka(ů). Odebírá z jedné nebo více front a konzumuje zprávy vytažením dat od prostředníků.

4.2 Úložiště

Tato sekce se zaměřuje na úložiště, kde budou digitální forenzní data uchována. Můžeme je rozdělit na strukturovaná a nestrukturovaná.

4.2.1 Strukturovaná data

V souvislosti se systémem repositáře se obecně jedná o data, která mohou být rozdělena na menší části při zachování možnosti interpretace, a mohou být efektivně serializována pro uložení. Mezi strukturovaná data můžeme zařadit například soubory formátu PCAP obsahující síťovou komunikaci. Tyto soubory lze rozparsovat na jednotlivé segmenty pakety. Pakety lze potom serializovat na pole bajtů a uložit do NoSQL databáze. Pro strukturovaná data byla vybrána databáze Cassandra.

Cassandra

Jedná se o zástupce sloupcových NoSQL databází. Výhodami jsou předně: škálovatelnost, odolnost proti chybám, rychlost, distribuovanost, konzistence a podpora transakcí. Cassandra využívají i světoznámé společnosti Facebook, Twitter, Cisco, ebay, Twitter, Netflix a další. Cílem Cassandry je zvládat vysoké objemy dat napříč mnoha uzly. Data jsou pak distribuována na všech uzlech clusteru. Uzly lze libovolně přidávat. Každý uzel je nezávislý a zároveň propojený s ostatními. Každý uzel v clusteru se může podílet na požadavcích čtení a zápisu nezávisle na tom, kde jsou data skutečně uložena. Když uzel selže, požadavky čtení a zápisu mohou být obslouženy jinými uzly sítě [16].

4.2.2 Nestrukturovaná data

Pro uchování nestrukturovaných dat typu například audio a video bude sloužit distribuovaný souborový systém, například HDFS. Taková data mohou mít velký objem, a bylo by plýtvání výkonem provádět jejich serializaci nebo rozdělování na části při ukládání do NoSQL databází.

4.2.3 Metadata

V rámci zpracování příchozí zprávy do repositáře informující o operaci uložení, by bylo vhodné provést předzpracování dat za účelem vhodnější indexace a rychlejšího nalezení pro budoucí operace čtení. Jednalo by se tak o mechanismus podobný například pamětem cache. Uvažme následující scénář pro podrobnější vysvětlení.

Do repositáře bylo v průběhu několika dnů uloženo mnoho milionů paketů, které obsahovaly síťovou komunikaci mezi několika komunikujícími stranami. Data paketů jsou uložena v serializované podobě v NoSQL databázi. Na úrovni databáze nedávají taková data žádný význam, pouze aplikace je dokáže správně interpretovat jako pakety. Po několika dnech by uživatel rád zjistil podrobnější informace o komunikaci mezi uzly A a B. Nezbyvalo by mu nic jiného, než všechna data z NoSQL databáze načíst na aplikační úrovni a analyzovat paket po paketu, aby zjistil minimálně IP adresy zdroje a cíle. Takový způsob by byl velmi pomalý a neefektivní.

Následně uvažme, jak by vypadal postup pro zjištění informací o komunikaci mezi uzly A a B, kdyby byla k dispozici cache, či paměť metadat. Cache by mohla uchovávat základní informace o dříve uložených paketech v jednotně definované struktuře. Mezi tyto informace

by patřily - zdrojová a cílová IP adresa, zdrojová a cílová MAC adresa, typ protokolu, timestamp a další. Co je však důležité, u těchto informací by bylo uvedeno ID záznamu z NoSQL databáze, kde je uchován celý paket. Pro zjištění podrobnějších informací by uživatel mohl načíst pouze ty pakety, které jsou pro něj relevantní.

Předzpracování dat je výhodné před jejich uložením, protože v kontextu provádění aplikace jsou data interpretovatelná. Výtah základních informací z nich nezpůsobí propad výkonu. Naopak se výkon zvýší pro případné operace čtení a hledání.

Výše uvedený princip by se dal zobecnit pro libovolný typ forenzních digitálních dat. Tak by došlo k vytvoření tzv. registru, který by i mimo jiné informoval, co je jak a kde uloženo. Vhodnou strukturou pro uložení těchto metadat může být například formát XML nebo JSON. Z toho vyplývá použití dokumentové NoSQL databáze jako například MongoDB.

MongoDB

MongoDB je multiplatformní, dokumentově orientovaná databáze poskytující vysoký výkon a dostupnost a jednoduchou škálovatelnost. Pracuje na principu kolekcí, které nevyžadují schéma. Kolekce je skupina MongoDB dokumentů, a je ekvivalentem SŘBD tabulek. Dokumenty v kolekcích mohou mít dynamická schémata a rozdílné atributy. Dynamické schéma znamená, že dokumenty ve stejné kolekci nemusí mít stejnou strukturu atributů. Počet atributů, obsah a velikost dokumentu se může mezi dokumenty lišit. Dokument je množina párů klíč-hodnota [18].

Relační databáze má určité schéma skládající se z tabulek a vztahů mezi nimi. V MongoDB je koncept vztahu řešen jinak. Existují dva mechanismy umožňující aplikaci reprezentovat vztahy: reference a vnořené dokumenty. Reference uchovávají vztahy mezi daty vložením odkazů (referencí) z jednoho dokumentu do druhého. Aplikace může díky odkazu přistoupit k příslušným datům. Vnořené dokumenty zachycují vztahy mezi daty ukládáním příslušných dat přímo do jednoho dokumentu. Namísto atributu dokumentu může být uložen i jiný dokument. Výhoda tohoto modelu je, že aplikace získá všechna data v jedné databázové operaci [3].

Dynamičnost MongoDB je vhodná pro správu metadat, zvláště když bude do repositáře potřeba přidávat nové druhy dat.

4.3 Zpracování zpráv

V předchozích sekcích byla představena komunikace s repositářem, jak vypadají příkazy a jakým způsobem jsou posílána data. Následně byly popsány možnosti ukládání. Tato sekce se zaměřuje na jádro distribuovaného repositáře, převážně na zpracování příkazů a manipulaci s databázemi.

Přijetí příkazu zajišťuje konzument zpráv. Konzument se v krátkých časových intervalech dotazuje na zprávy z Kafka fronty. Po přijetí zprávy dojde k přečtení příkazu určeného typem operace a typem dat společně s dodatečnými informacemi. Podle typu operace a typu dat se sestaví objekt příkazu. Na základě něj dojde k výběru konkrétní akce (tzv. **handler**), která má za úkol zpracování příkazu. Může se jednat o uložení dat, o načtení dat podle zadaných parametrů, přečtení metadat apod. Handler ukrývá všechny potřebné operace, které mají proběhnout při zpracování příkazu. Mimo jiné se jedná i o správu metadat zmíněnou v sekci 4.2.3. Při implementaci je handleru nastaven konkrétní odpovídající objekt, který řeší databázové operace pro daný typ dat. Každý typ úložiště (souborový systém nebo NoSQL databáze) může mít jiné rozhraní přístupu.

4.4 Architektura

Tato sekce se zabývá architekturou systému, jak bude repositář implementován. Diagram tříd 4.3 zobrazuje z důvodu přehlednosti pouze klíčová rozhraní a třídy systému. Nejsou zde vyznačeny všechny implementační třídy a všechny vazby závislosti.

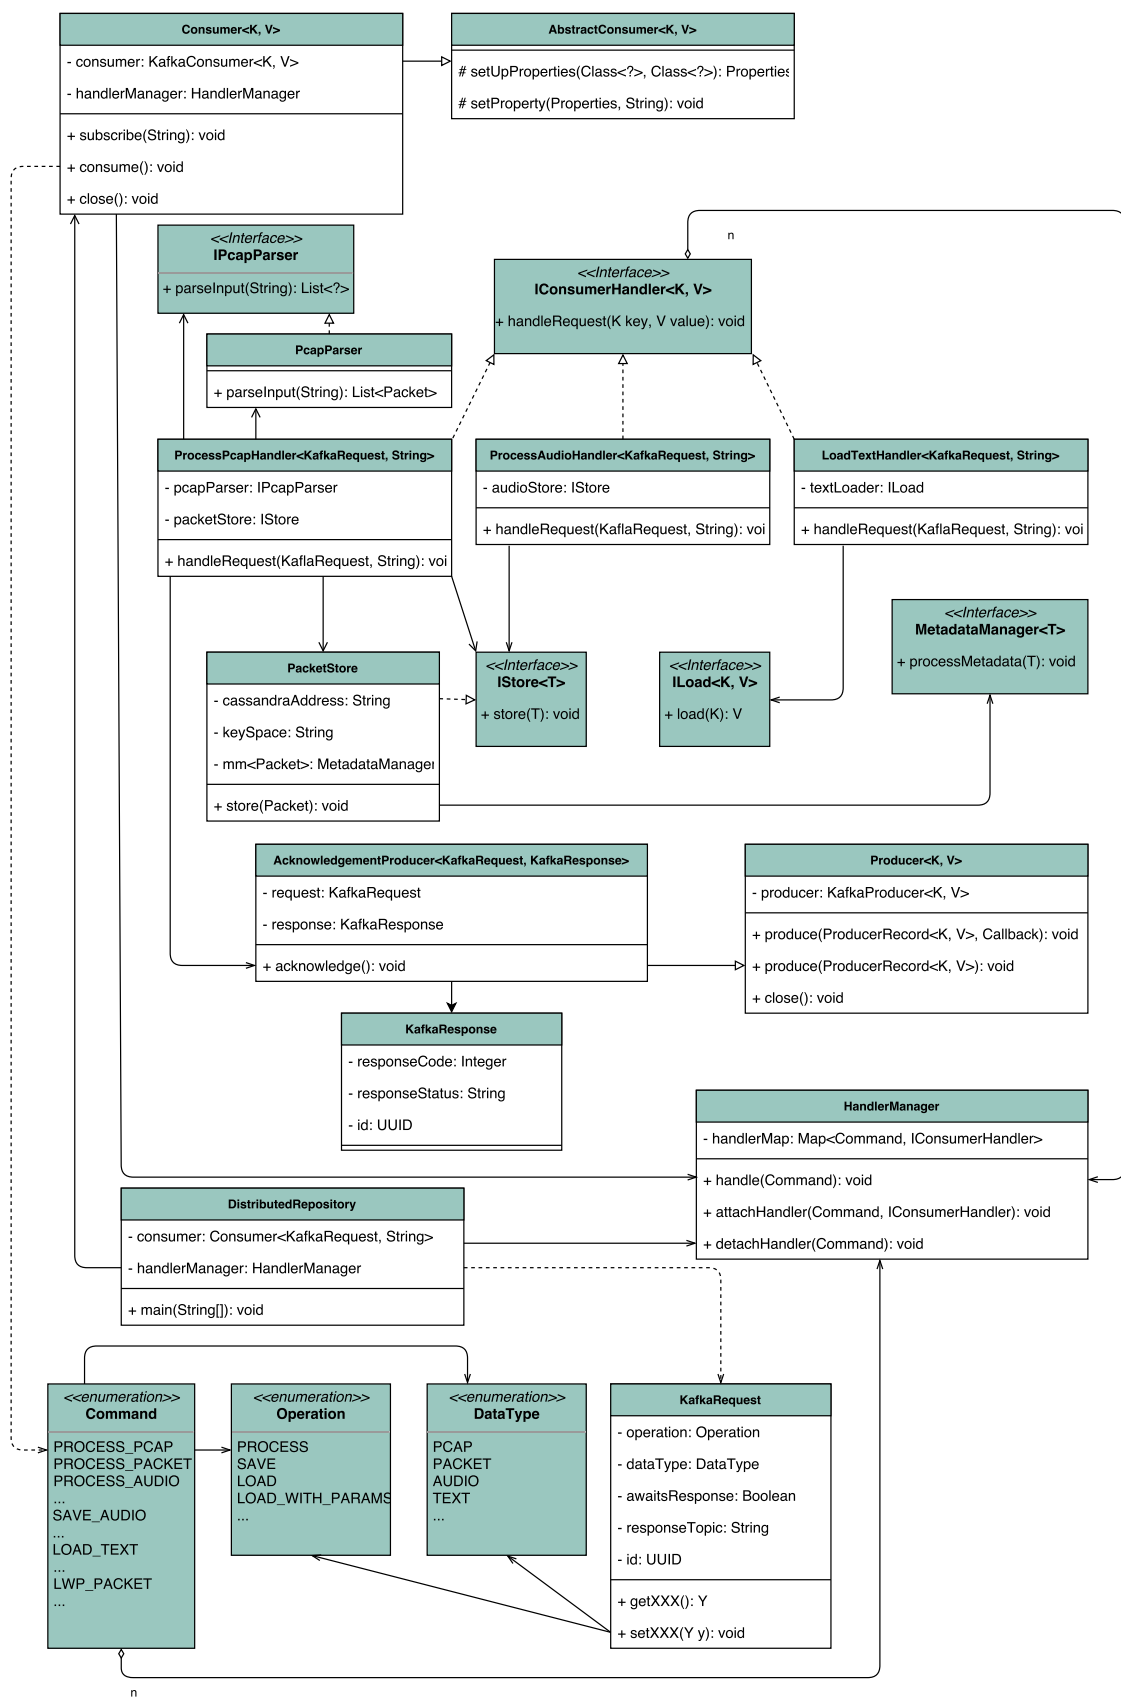
Tok začíná ve třídě `DistributedRepository`, která zapouzdřuje konzumenta Kafka front a správce všech handlerů. Konzument přijme zprávu z fronty, sestaví objekt příkazu na základě typu operace a typu dat, a vybere podle něj korespondující handler ze správce handlerů. Handler potom zpracuje příkaz. V rámci zpracování může být odeslána asynchronní odpověď klientovi, pokud klient nastavil při odeslání zprávy parametry `awaitResponse` a `responseTopic`. Odpověď může obsahovat základní informace jako například kód a status, a také ID, aby si klient dokázal spárovat zpracované zprávy.

Rozšíření v podobě podpory nových druhů digitálních forenzních dat je velmi jednoduché. Spočívá v rozšíření výčtů `Command`, `Operation` a `DataType`. Dále je potřeba implementovat rozhraní `IConsumerHandler`, které kompletně řídí zpracování příkazu. Pro nový druh dat a potřeby komunikace s úložištěm nebo databází je nutné přidat implementaci rozhraní `IStore` a/nebo `ILoad`. Nová třída handleru musí být přidána do správce handlerů společně s typem příkazu.

Díky tomu že jsou typ operace a typ dat výčty, nemůže klient poslat libovolný dotaz na úplně neznámá data. Příkaz je ale určen kombinací těchto dvou výčtů, a proto i tak lze odeslat nepodporovaný příkaz, který může skončit chybou.

Všechny výše zmíněné technologie, tzn. Kafka, Cassandra, MongoDB, i HDFS, jsou distribuované, je možné přidávat další uzly pro navýšení výkonu, a všechny tak počítají s rozšiřitelností do budoucna.

Konfigurace parametrů systému a jednotlivých technologií bude možná pomocí specifických souborů s příponou `.properties` skládajících se z dvojic klíč-hodnota.



Obrázek 4.3: Diagram tříd systému.

Kapitola 5

Implementace prototypu

Prototyp distribuovaného repositáře byl implementován za účelem ověření základních aspektů návrhu, k ověření komunikace mezi klientem a systémem, zpracování příkazů, a také výkonu.

Prototyp má omezenou funkcionalitu co se týká zpracování různých druhů digitálních forenzních dat a z hlediska operací. Neobsahuje také ani systém metadat. Podporuje pouze operaci uložení a pro soubory typu PCAP.

Klient tedy může odeslat příkaz pro operaci **SAVE** a typ dat PCAP. Konzument zpráv zprávu přijme a spustí odpovídající handler. Jak bylo výše uvedeno, soubory typu PCAP lze považovat za strukturovaná data. Handler tedy soubor rozdělí na jednotlivé pakety a ty jsou potom serializovány a uloženy do Cassandra. Klientovi je odeslána odpověď informující o dokončení. Systém využívá knihovnu `pcap4j`¹ pro rozdělení na pakety.

5.1 Výkon

Tato sekce se věnuje shrnutí výkonnosti implementovaného prototypu. Test rychlosti byl proveden na této konfiguraci:

CPU: Intel Core i5-4200U 1.6Ghz @ 2.3Ghz

RAM: 8 GB


OS: Windows 8.1

Kafka, Zookeeper and Cassandra: running as containers in Docker environment hosted by boot2docker

Pro testování byly použity PCAP soubory obsahující od stovek paketů po několik tisíc. Tabulka 5.1 obsahuje informace z měření. První sloupec udává velikost PCAP souboru v bytech, druhý sloupec obsahuje počet paketů na daný PCAP soubor a třetí sloupec zobrazuje průměrnou velikost paketu. Čas uvedený ve čtvrtém sloupci je měřen od odeslání příkazu od klienta po obdržení odpovědi z repositáře. Poslední pátý sloupec udává počet paketů zpracovaných za sekundu. Pro test PCAP souborů větších než 30 MB (obsahujících přes 100 tisíc paketů) už výše uvedená konfigurace nestačila. Po několika minutách aplikace zhavarovala pro nedostatek paměti RAM.

Z výše uvedené hardwarové konfigurace vyplývá, že nebylo využito maximálního potenciálu použitých technologií, a to zejména distribuovanosti systému, který by běžel místo jednoho počítače v clusteru. V takovém prostředí by byla výkonnost systému znatelně vyšší.

¹<https://github.com/kaitoy/pcap4j>



Obrázek 5.1: Graf zobrazující počet uložených paketů z jednoho PCAP souboru za čas.

Z uvedeného grafu 5.1 vyplývá lineární složitost. Podle údajů v tabulce 5.1 lze průměrně zpracovat 89 paketů za sekundu při průměrné velikosti jednoho paketu 450 bytů.

PCAP size (bytes)	Count of packets	Avg. packet size	Time (s)	Packets/s
91 340	382	239,1099476	7	54,57142857
1 955 172	1360	1437,626471	13	104,6153846
412 254	1879	219,4007451	19	98,89473684
420 869	2263	185,9783473	23	98,39130435
449 234	2563	175,276629	29	88,37931034

Tabulka 5.1: Tabulka obsahuje měřená data.

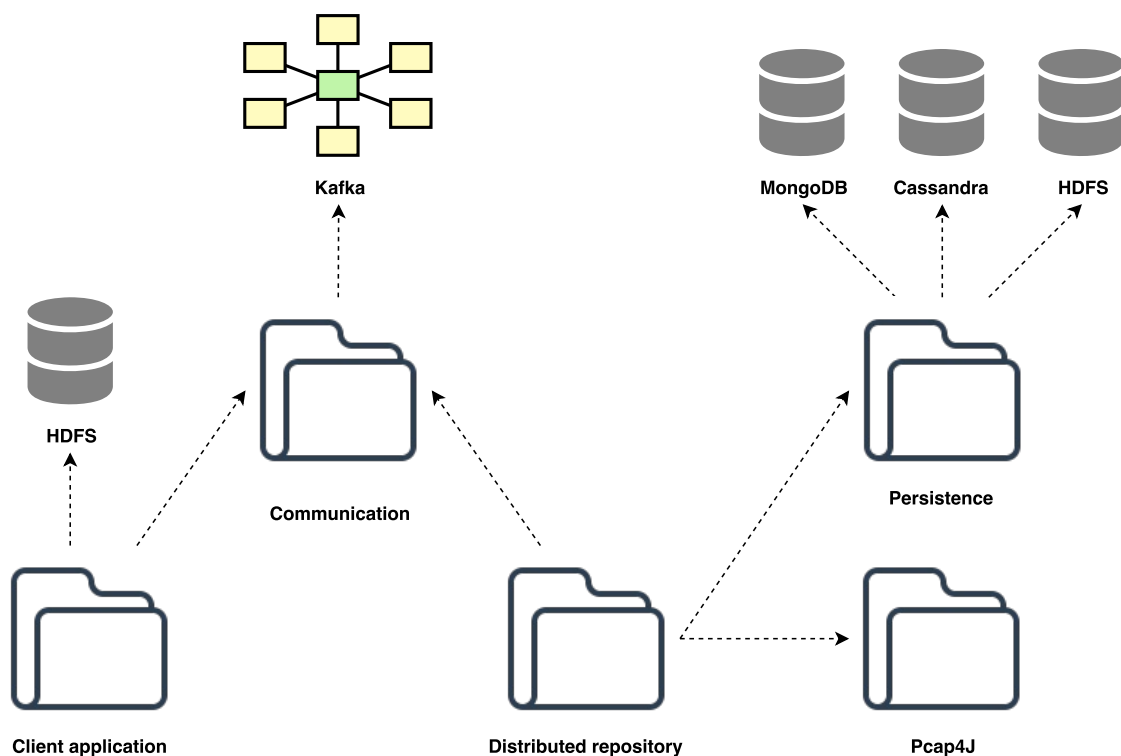
Kapitola 6

Implementace

6.1 Rozhraní pro dotazování dat

6.2 Moduly, knihovny a frameworky

Repositář je komplexní distribuovaný systém, který je postaven na frameworku Spring, sestávající z několika modulů a knihoven. V této sekci je uvedeno, jak byl systém dekomponován do modulů a jaké knihovny byly zvoleny. Pro správu závislostí a sestavení aplikace byl zvolen nástroj Maven.



Obrázek 6.1: Schéma závislostí systému.

6.2.1 Pcap4J

Jedná se o knihovnu pro jazyk Java pro zachytávání, sestavení a odesílání paketů. Knihovna je stále ve vývoji. Pcap4J pracuje nad nativní knihovnou (`libpcap`, `WinPcap`, nebo `Npcap` podle operačního systému) přes JNA (`Java Native Access`) a poskytuje aplikační rozhraní pro jazyk Java. Mimo výše uvedené činnosti dokáže pracovat s PCAP soubory, vytvářet a parsovat je na jednotlivé pakety. Každý paket implementuje rozhraní `Packet`. Toto rozhraní nabízí mimo jiné dvě klíčové metody `contains` a `get`. Metoda `contains` slouží ke kontrole, jestli je paket konkrétního typu, který chceme získat. Metoda má jako parametr třídu, které je paket typem, hlavička metody potom vypadá:

```
boolean contains(Class<T> clazz)
```

Ke konkrétnímu typu paketu, např. IP paketu, se přistupuje pomocí reflexe voláním metody:

```
T get(Class<T> clazz)
```


Tedy například:

```
IPv4Packet ipv4Packet = ethernetPacket.get(IPv4Packet.class);
```

Návratová hodnota metody `get` je objekt třídy uvedené v parametru. Před voláním `get` je vhodné zkontrolovat typ pomocí metody `contains`. Z konkrétního paketu už lze získávat potřebné informace, v případě IP paketu údaje z hlavičky jako zdrojová a cílová IP adresa, verze protokolu apod. Analogicky lze postupovat i v případě ostatních typů paketů, Z TCP paketu lze získat údaje o portech, sekvenční čísla, checksum a další.

Knihovna reflektuje zapouzdření, které spočívá ve vložení protokolové datové jednotky (anglicky `Protocol Data Unit`) vyšší vrstvy do protokolové jednotky nižší vrstvy. Takže ethernetový paket může být současně i IP paketem a podobně.

```
getPayload(), or iterator().next(), or get(IPv4Packet.class)
```



Obrázek 6.2: Schéma znázorňující výše uvedený příklad pro manipulaci s pakety [20].

6.3 Scénáře

6.3.1 Ukládání paketů

6.3.2 Čtení paketů

6.4 Komunikace s databázemi

6.4.1 Reaktivní paradigma

6.4.2 Asynchronní dotazy

6.5 Logování

6.6 Zpracování chyb

Kapitola 7

Výkon

Kapitola 8

Závěr

V rámci semestrálního projektu jsem se seznámil s formáty digitálních forenzních dat a způsoby jejich uložení. Prozkoumal jsem existující systémy pro uložení digitálních forenzních dat (včetně AFF4). Seznámil jsem se s distribuovanými databázemi a NoSQL databázemi. Navrhl jsem distribuované úložiště rozsáhlých digitálních forenzních dat včetně aplikačního rozhraní.

Pro ověření základních aspektů návrhu jsem také implementoval prototyp distribuovaného repositáře, který realizuje rozhraní komunikace s klientem, způsob ovládání repositáře, a rovněž zpracovává požadavky od klienta. Provedl jsem také základní vyhodnocení z hlediska výkonnosti na běžně dostupné hardwarové konfiguraci.

Dalším krokem bude rozšíření implementace prototypu o podporu nových druhů digitálních forenzních dat, zejména zjednodušení přidávání nových akcí, které zpracovávají příkazy od klienta. Bude také implementován podsystém metadat, který bude provádět předzpracování dat. Implementovaný systém bude zhodnocen z hlediska výkonu a použití pro vybrané druhy digitálních forenzních dat.

Literatura

- [1] *Advanced Forensic Framework 4 (AFF4)*. [Online; navštíveno 28.10.2017].
URL <http://forensicswiki.org/wiki/AFF4>
- [2] *Data model*. [Online; navštíveno 22.12.2017].
URL https://en.wikipedia.org/wiki/Data_model
- [3] *Data Modeling Introduction — MongoDB Manual 3.6*. [Online; navštíveno 27.12.2017].
URL <https://docs.mongodb.com/manual/core/data-modeling-introduction/>
- [4] *Distributed database*. [Online; navštíveno 02.10.2017].
URL https://en.wikipedia.org/wiki/Distributed_database
- [5] *File Format Identification*. [Online; navštíveno 01.04.2018].
URL http://www.forensicswiki.org/wiki/File_Format_Identification
- [6] *Forensics File Formats*. [Online; navštíveno 28.10.2017].
URL http://www.forensicswiki.org/wiki/Category:Forensics_File_Formats
- [7] *NoSQL*. [Online; navštíveno 22.12.2017].
URL <https://cs.wikipedia.org/wiki/NoSQL>
- [8] *NoSQL introduction*. [Online; navštíveno 22.12.2017].
URL <https://www.w3resource.com/mongodb/nosql.php>
- [9] Heller, P.; Piziak, D.; Stackowiak, R.; aj.: *An Enterprise Architect's Guide to Big Data*. [Online; navštíveno 26.09.2017].
URL <http://www.oracle.com/technetwork/topics/entarch/articles/oea-big-data-guide-1522052.pdf>
- [10] Nambiar, R.: *What is Big Data ?*. [Online; navštíveno 27.09.2017].
URL <http://rrnamb.blogspot.cz/2012/09/what-is-big-data.html>
- [11] Oracle Help Center: *Distributed Database Architecture*. [Online; navštíveno 29.09.2017].
URL https://docs.oracle.com/cd/B28359_01/server.111/b28310/ds_concepts001.htm
- [12] Rouse, M.: *What is slack space (file slack space)?* [Online; navštíveno 01.04.2018].
URL <http://whatis.techtarget.com/definition/slack-space-file-slack-space>

- [13] Sadalage, P.: *NoSQL Databases: An Overview*. [Online; navštíveno 22.12.2017].
URL <https://www.thoughtworks.com/insights/blog/nosql-databases-overview>
- [14] Stephens, B.: *What Is Digital Forensics?* [Online; navštíveno 28.10.2017].
URL <https://www.interworks.com/blog/bstephens/2016/02/05/what-digital-forensics>
- [15] Tutorials Point (I) Pvt. Ltd.: *Apache Kafka Tutorial*. [Online; navštíveno 23.12.2017].
URL https://www.tutorialspoint.com/apache_kafka/
- [16] Tutorials Point (I) Pvt. Ltd.: *Cassandra Introduction*. [Online; navštíveno 26.12.2017].
URL <https://www.tutorialspoint.com/cassandra/index.htm>
- [17] Tutorials Point (I) Pvt. Ltd.: *Distributed DBMS Tutorial*. [Online; navštíveno 29.09.2017].
URL https://www.tutorialspoint.com/distributed_dbms/
- [18] Tutorials Point (I) Pvt. Ltd.: *MongoDB Tutorial*. [Online; navštíveno 27.12.2017].
URL <https://www.tutorialspoint.com/mongodb/index.htm>
- [19] Vandeven, S.: *Forensic Images: For Your Viewing Pleasure*. [Online; navštíveno 28.10.2017].
URL <https://www.sans.org/reading-room/whitepapers/forensics/forensic-images-viewing-pleasure-35447>
- [20] Yamada, K.: *Pcap4J*. [Online; navštíveno 01.04.2018].
URL <https://github.com/kaitoy/pcap4j>